# Red neuronal multicapa con retropropagación: clasificación del estado nutricional en cuatro categorías a partir de altura y peso

1st Oscar Alberto Gallo García
*M. C. en Robótica e Inteligencia Artificial*
*Centro Universitario de Ciencias Exactas e Ingenierías*
Guadalajara, México
oscar.gallo5770@alumnos.udg.mx

***Resumen*—Se implementó desde cero un perceptrón multicapa con una capa oculta, entrenado mediante el algoritmo de retropropagación del error en modalidad estocástica. La red se empleó para clasificar a adultos mexicanos de la ENSANUT 2022 en las cuatro categorías de la OMS, bajo peso, peso normal, sobrepeso y obesidad, utilizando únicamente su altura y su peso como entradas. El índice de masa corporal se utilizó exclusivamente para construir las etiquetas. Con una arquitectura 2–6–4, activación sigmoide logística en ambas capas y codificación *one-hot*, la energía promedio del error descendió de $0{,}3246$ a $0{,}0266$ en $200$ épocas y la exactitud alcanzó $97{,}12\,\%$ en el conjunto de prueba. La red construyó regiones de decisión independientes para las clases peso normal, sobrepeso y obesidad, cuyos errores se concentran en las fronteras teóricas $m = 25h^2$ y $m = 30h^2$, superando la limitación de la frontera lineal única de ADALINE. No obstante, la clase bajo peso, que representa apenas el $1{,}4\,\%$ de los datos, no fue reconocida por la red, lo cual evidencia el efecto del desbalance de clases sobre el criterio de error cuadrático.**

***Index Terms*—Perceptrón multicapa, retropropagación, descenso de gradiente estocástico, clasificación multiclase, regiones de decisión, IMC**

## I. Introducción

En la práctica anterior se estudió ADALINE, una neurona lineal cuyo aprendizaje se formula como la minimización de una función de costo cuadrática mediante descenso de gradiente. Dicho modelo solo es capaz de representar una frontera lineal, por lo que su desempeño quedó limitado por la curvatura de la frontera real $m = 25h^2$ en el plano altura–peso.

El perceptrón multicapa generaliza esta idea al introducir una o más capas ocultas con funciones de activación no lineales. La dificultad adicional consiste en que los pesos de las capas ocultas influyen en el error de manera indirecta. El algoritmo de retropropagación resuelve este problema aplicando la regla de la cadena para atribuir a cada neurona un gradiente local, el cual se propaga desde la capa de salida hacia las capas anteriores [1]–[5].

En esta práctica se conservan las cuatro categorías originales del IMC. Como las fronteras ideales entre ellas son las parábolas

$$m = 18{,}5h^2, \qquad m = 25h^2, \qquad m = 30h^2, \tag{1}$$

con $h$ en metros y $m$ en kilogramos, el problema exige construir regiones de decisión no lineales, lo que permite evaluar directamente la capacidad de representación que aporta la capa oculta.

## II. Desarrollo

### II-A. Base de datos

Se utilizó la misma base de antropometría de la *Encuesta Nacional de Salud y Nutrición Continua 2022*, ENSANUT 2022, archivo `ensaantro2022_entrega_w.csv`, publicada por el Instituto Nacional de Salud Pública de México [6]. La base original contiene $15\,073$ registros y $98$ columnas, de las cuales se emplearon el peso `an01_1`, la estatura `an04_1`, la edad `h0303` y la condición de embarazo o lactancia `an06`.

Se aplicó exactamente la misma limpieza que en la Práctica 2, con el fin de que los resultados de ambos modelos fueran comparables. Las columnas se convirtieron a tipo numérico y se conservaron únicamente los registros que cumplían simultáneamente las siguientes condiciones:

- peso válido, $2 \le \text{peso} \le 250$ kg;
- estatura válida, $40 \le \text{estatura} \le 230$ cm;
- edad adulta, $20 \le \text{edad} \le 110$ años, ya que los puntos de corte del IMC de la OMS solo aplican a adultos;
- ausencia de embarazo y lactancia, $\texttt{an06} \notin \{1, 2, 3\}$.

La estatura se convirtió a metros. Tras la limpieza quedaron $N = 6\,246$ registros, con alturas entre $1{,}065$ y $2{,}222$ m y pesos entre $32{,}05$ y $222{,}22$ kg.

### II-B. Construcción de las cuatro clases

Para cada registro se calculó el índice de masa corporal con las unidades físicas originales,

$$\text{IMC}(k) = \frac{\text{peso}(k)\,[\text{kg}]}{\left(\text{altura}(k)\,[\text{m}]\right)^2}, \tag{2}$$

y se asignó una de las cuatro clases de la OMS:

$$\begin{aligned} C_1&: \text{ Bajo peso}, && \text{IMC} < 18{,}5, \\ C_2&: \text{ Peso normal}, && 18{,}5 \le \text{IMC} < 25, \\ C_3&: \text{ Sobrepeso}, && 25 \le \text{IMC} < 30, \\ C_4&: \text{ Obesidad}, && \text{IMC} \ge 30. \end{aligned} \tag{3}$$

El IMC se utilizó exclusivamente para generar la salida deseada y nunca formó parte del vector de entrada, que se mantuvo como $\mathbf{X}(k) = [\text{altura}(k),\ \text{peso}(k)]^\top$. El Cuadro I y la Fig. 1 muestran un desbalance severo: la clase $C_1$ contiene únicamente 85 registros, es decir, el 1,36 % del total, mientras que $C_3$ y $C_4$ concentran conjuntamente el 78,1 %.

Cuadro I
DISTRIBUCIÓN DE PATRONES POR CLASE

| Clase | Total | % | Entren. | Prueba |
|---|---|---|---|---|
| $C_1$ Bajo peso | 85 | 1,36 | 70 | 15 |
| $C_2$ Peso normal | 1 286 | 20,59 | 1 031 | 255 |
| $C_3$ Sobrepeso | 2 288 | 36,63 | 1 834 | 454 |
| $C_4$ Obesidad | 2 587 | 41,42 | 2 062 | 525 |
| Total | 6 246 | 100 | 4 997 | 1 249 |

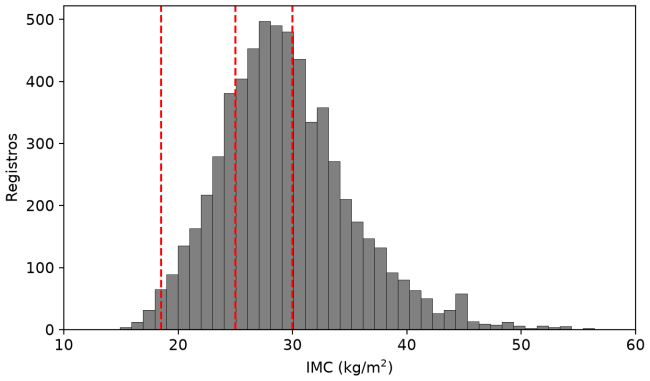



Figura 1. Histograma del IMC de los datos limpios. Las líneas punteadas indican los umbrales 18,5, 25 y 30 que separan las cuatro clases.

Las clases se representaron mediante codificación *one-hot*, la cual es consistente con el rango $[0, 1]$ de la sigmoide logística empleada en la capa de salida:

$$\begin{aligned} \mathbf{d}_{C_1} &= [1\ 0\ 0\ 0]^\top, \quad \mathbf{d}_{C_2} = [0\ 1\ 0\ 0]^\top, \\ \mathbf{d}_{C_3} &= [0\ 0\ 1\ 0]^\top, \quad \mathbf{d}_{C_4} = [0\ 0\ 0\ 1]^\top. \end{aligned} \tag{4}$$

### II-C. *Partición y escalamiento*

Se conservó la misma división de la Práctica 2: 80 % de los patrones para entrenamiento, 4 997 en total, y 20 % para prueba, 1 249 en total, mediante muestreo aleatorio con semilla fija `random_state=42`. Las proporciones de cada clase se mantienen prácticamente iguales en ambas particiones, como se aprecia en el Cuadro I.

Las entradas se estandarizaron con

$$z_j(k) = \frac{x_j(k) - \mu_j}{\sigma_j}, \tag{5}$$

con $\mu_1 = 1{,}5946$ m y $\sigma_1 = 0{,}1076$ m para la altura, y $\mu_2 = 75{,}181$ kg y $\sigma_2 = 19{,}570$ kg para el peso, calculados únicamente con los 4 997 patrones de entrenamiento. Se eligió la estandarización porque en la práctica anterior demostró un condicionamiento claramente superior al de la normalización Min–Max. Los mismos parámetros se reutilizaron sin cambios para transformar el conjunto de prueba y la malla del mapa de regiones de decisión.

### II-D. *Arquitectura de la red*

La red implementada tiene la estructura 2–6–4: dos entradas, una capa oculta con $N_h = 6$ neuronas y cuatro neuronas de salida, una por clase [1]. La Fig. 2 muestra la arquitectura y la notación empleada, donde $w_{ji}^{(\ell)}$ conecta la neurona $i$ de la capa $\ell - 1$ con la neurona $j$ de la capa $\ell$. El número total de parámetros libres es $6 \cdot 2 + 6 + 4 \cdot 6 + 4 = 46$.

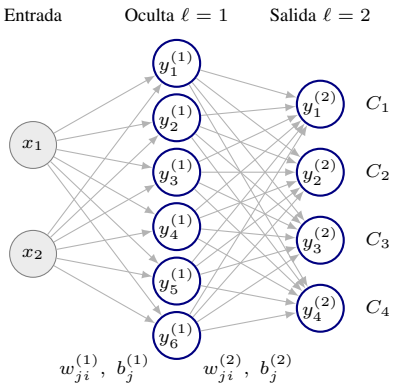



Figura 2. Arquitectura 2–6–4 implementada. Ambas capas utilizan la sigmoide logística como función de activación.

### II-E. *Propagación hacia adelante*

Definiendo $y_i^{(0)}(k) = x_i(k)$, el potencial local y la salida de la neurona $j$ en la capa $\ell \in \{1, 2\}$ son

$$v_j^{(\ell)}(k) = \sum_i w_{ji}^{(\ell)}(k)\, y_i^{(\ell-1)}(k) + b_j^{(\ell)}(k), \tag{6}$$

$$y_j^{(\ell)}(k) = \varphi\Big(v_j^{(\ell)}(k)\Big). \tag{7}$$

En forma matricial, que es como se programó, la propagación se expresa como $\mathbf{y}^{(\ell)} = \varphi\big(\mathbf{W}^{(\ell)}\mathbf{y}^{(\ell-1)} + \mathbf{b}^{(\ell)}\big)$, con $\mathbf{W}^{(1)} \in \mathbb{R}^{6\times 2}$ y $\mathbf{W}^{(2)} \in \mathbb{R}^{4\times 6}$. En ambas capas se utilizó la sigmoide logística con $a = 1$, cuya derivada se programó explícitamente en términos de su propia salida:

$$\varphi(v) = \frac{1}{1 + e^{-v}}, \qquad \varphi'(v) = \varphi(v)\,[1 - \varphi(v)]. \tag{8}$$

La clase predicha corresponde a la neurona de salida con mayor activación,

$$\hat{C}(k) = \arg \max_{j \in \{1,2,3,4\}} y_j^{(2)}(k). \tag{9}$$

### II-F. *Función de error*

Para cada neurona de salida se define $e_j(k) = d_j(k) - y_j^{(2)}(k)$. La energía instantánea del error y la energía promedio de una época son

$$E(k) = \frac{1}{2}\sum_{j=1}^{4} e_j^2(k), \qquad E_{\text{av}} = \frac{1}{N}\sum_{k=1}^{N} E(k). \tag{10}$$

La cantidad $E_{\text{av}}$ se registró al final de cada época y constituye la curva de aprendizaje.

### II-G. Retropropagación

Al aplicar la regla de la cadena, el gradiente local de una neurona de salida resulta

$$\delta_j^{(2)}(k) = e_j(k)\,\varphi'\Big(v_j^{(2)}(k)\Big) = e_j(k)\,y_j^{(2)}(k)\,\Big[1 - y_j^{(2)}(k)\Big]. \tag{11}$$

Una neurona oculta carece de salida deseada; su contribución al error se obtiene a través de las neuronas de la capa siguiente:

$$\delta_j^{(1)}(k) = y_j^{(1)}(k)\,\Big[1 - y_j^{(1)}(k)\Big] \sum_{r=1}^{4} \delta_r^{(2)}(k)\,w_{rj}^{(2)}(k). \tag{12}$$

En forma matricial, $\boldsymbol{\delta}^{(1)} = \Big(\mathbf{W}^{(2)\top}\boldsymbol{\delta}^{(2)}\Big) \odot \varphi'\big(\mathbf{v}^{(1)}\big)$. Finalmente, todos los pesos y sesgos se actualizan con la regla general

$$w_{ji}^{(\ell)}(k+1) = w_{ji}^{(\ell)}(k) + \eta\,\delta_j^{(\ell)}(k)\,y_i^{(\ell-1)}(k), \tag{13}$$

$$b_j^{(\ell)}(k+1) = b_j^{(\ell)}(k) + \eta\,\delta_j^{(\ell)}(k). \tag{14}$$

Los gradientes locales de ambas capas se calculan con los pesos vigentes antes de modificar cualquier parámetro, de modo que la actualización es coherente con el estado de la red para el patrón $k$.

### II-H. Parámetros de diseño

El Cuadro II resume la configuración utilizada. Se eligió la modalidad estocástica, en la que los parámetros se actualizan inmediatamente después de presentar cada patrón, lo que produce $N$ actualizaciones por época.

Cuadro II
PARÁMETROS DE DISEÑO DE LA RED MULTICAPA

| Parámetro | Valor |
|---|---|
| Arquitectura | 2–6–4, 46 parámetros |
| Activación oculta | Sigmoide logística, $a = 1$ |
| Activación de salida | Sigmoide logística, $a = 1$ |
| Codificación | *One-hot* en $\{0, 1\}$ |
| Inicialización | $w_{ji}^{(\ell)}, b_j^{(\ell)} \sim \mathcal{U}(-1, 1)$, semilla 42 |
| Modalidad | Estocástica, SGD, $M = 1$ |
| Orden de patrones | Fijo en todas las épocas |
| Razón de aprendizaje | $\eta = 0{,}01$ |
| Épocas | 200 |
| Criterio de paro | Número fijo de épocas |
| Escalamiento | Estandarización, z-score |

El valor $N_h = 6$ corresponde a una de las arquitecturas pequeñas sugeridas en los lineamientos. Con tres fronteras curvas que separar, seis neuronas ocultas proporcionan suficientes semiplanos sigmoidales para aproximar cada parábola por tramos, sin incrementar en exceso el número de parámetros.

### II-I. Algoritmo

El procedimiento se implementó en Python con NumPy, sin bibliotecas de redes neuronales ni diferenciación automática:

Inicializar $\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)} \sim \mathcal{U}(-1, 1)$
**for** $q = 1$ **to** 200 **do**
  $S \leftarrow 0$
  **for** cada patrón $k$ **do**
    $\mathbf{y}^{(0)} \leftarrow \mathbf{z}(k)$
    **for** $\ell = 1$ **to** 2 **do**
      $\mathbf{y}^{(\ell)} \leftarrow \varphi(\mathbf{W}^{(\ell)}\mathbf{y}^{(\ell-1)} + \mathbf{b}^{(\ell)})$
    **end for**
    $\boldsymbol{\delta}^{(2)} \leftarrow (\mathbf{d}(k) - \mathbf{y}^{(2)}) \odot \mathbf{y}^{(2)} \odot (1 - \mathbf{y}^{(2)})$
    $\boldsymbol{\delta}^{(1)} \leftarrow (\mathbf{W}^{(2)\top}\boldsymbol{\delta}^{(2)}) \odot \mathbf{y}^{(1)} \odot (1 - \mathbf{y}^{(1)})$
    **for** $\ell = 1$ **to** 2 **do**
      $\mathbf{W}^{(\ell)} \leftarrow \mathbf{W}^{(\ell)} + \eta\,\boldsymbol{\delta}^{(\ell)}\mathbf{y}^{(\ell-1)\top}$
      $\mathbf{b}^{(\ell)} \leftarrow \mathbf{b}^{(\ell)} + \eta\,\boldsymbol{\delta}^{(\ell)}$
    **end for**
    $S \leftarrow S + \frac{1}{2}\|\mathbf{d}(k) - \mathbf{y}^{(2)}\|^2$
  **end for**
  $E_{\text{av}}(q) \leftarrow S/N$
**end for**
Clasificar el conjunto de prueba con (9)

## III. RESULTADOS

### III-A. Curva de aprendizaje

La energía promedio descendió de $E_{\text{av}}(1) = 0{,}3246$ a $E_{\text{av}}(200) = 0{,}0266$, como se observa en la Fig. 3. El descenso fue rápido durante las primeras épocas, con $E_{\text{av}}(10) = 0{,}1481$, y posteriormente se volvió gradual, con $E_{\text{av}}(50) = 0{,}0433$ y $E_{\text{av}}(100) = 0{,}0329$. La curva es monótona y suave, sin indicios de divergencia ni de oscilaciones, lo cual confirma que $\eta = 0{,}01$ es adecuada para entradas estandarizadas. Al concluir las 200 épocas la curva aún presenta una pendiente ligeramente negativa, por lo que un entrenamiento más prolongado podría reducir marginalmente el error.

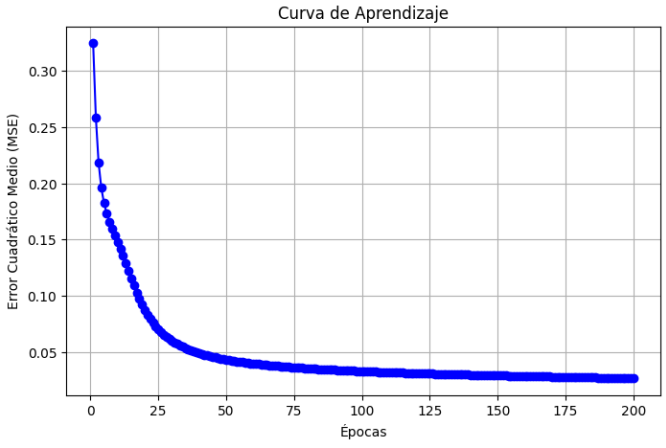



Figura 3. Curva de aprendizaje de la red 2–6–4. El eje vertical, rotulado como MSE, corresponde a la energía promedio del error $E_{\text{av}}$ definida en (10).

### *III-B. Regiones de decisión*

Para construir el mapa de decisión se generó una malla regular de puntos, con separación de $0{,}05$, sobre el espacio de entradas estandarizadas $(z_1, z_2)$, que cubre el intervalo de los datos con un margen de $0{,}5$ en cada eje. Cada punto se propagó por la red y se le asignó la clase con (9). Las Figs. 4 y 5 muestran las regiones obtenidas junto con los patrones reales de prueba y de entrenamiento, respectivamente. Los ejes corresponden a la altura y al peso estandarizados, de modo que un punto de la gráfica se relaciona con las unidades originales mediante $h = \mu_1 + \sigma_1 z_1$ y $m = \mu_2 + \sigma_2 z_2$.

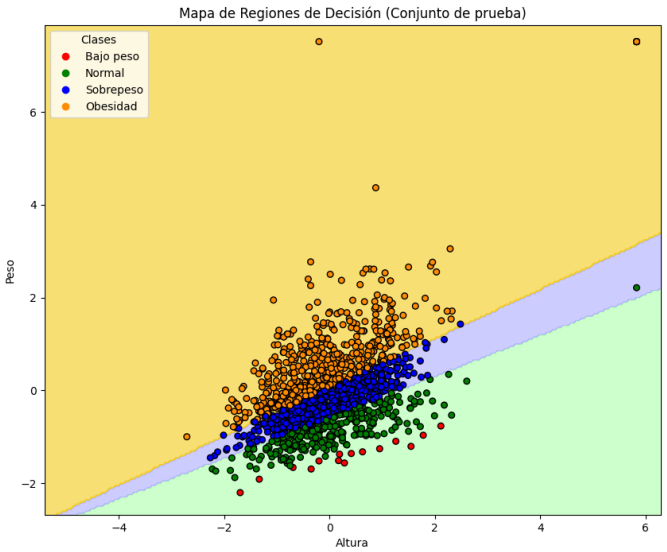



Figura 4. Regiones de decisión de la red 2–6–4 en el espacio estandarizado, con los patrones del conjunto de prueba.

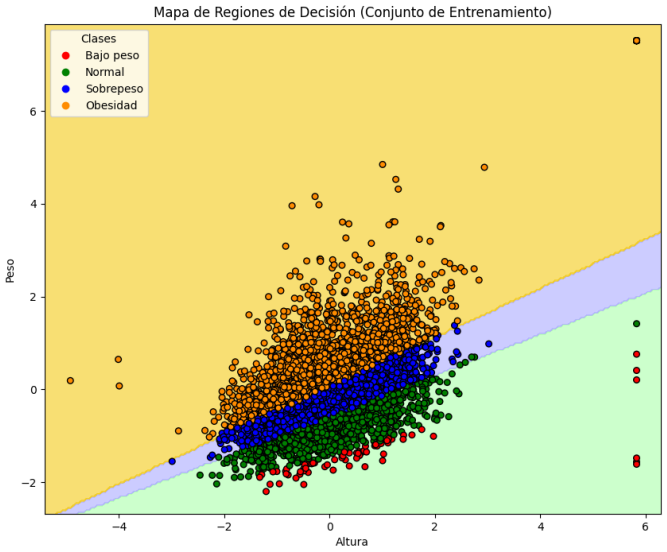



Figura 5. Regiones de decisión de la red 2–6–4 en el espacio estandarizado, con los patrones del conjunto de entrenamiento.

A diferencia de la única recta obtenida con ADALINE, la red construyó tres regiones separadas por dos fronteras independientes: una entre peso normal y sobrepeso y otra entre sobrepeso y obesidad. Ambas fronteras crecen con la altura, lo cual es coherente con las fronteras teóricas (1), según las cuales el peso límite de cada categoría aumenta con el cuadrado de la estatura. En la zona donde se concentran los patrones, aproximadamente $-2 \le z_1 \le 2$, las fronteras separan con claridad las nubes de puntos de $C_2$, $C_3$ y $C_4$, y los patrones de distinta clase solo se mezclan en las franjas contiguas a cada frontera. Dentro de este intervalo la curvatura de las parábolas teóricas es pequeña, por lo que las fronteras aprendidas resultan casi rectas. Fuera de él, donde los datos son escasos, las fronteras se prolongan con pendiente aproximadamente constante, ya que la red carece de información para extrapolar la curvatura real. Por último, no se formó ninguna región para $C_1$: los patrones de bajo peso, ubicados en la parte inferior de la nube, quedaron dentro de la región asignada a $C_2$.

### *III-C. Desempeño en entrenamiento y prueba*

El Cuadro III resume los resultados en ambos conjuntos. La exactitud global fue de $97{,}52\,\%$ en entrenamiento y de $97{,}12\,\%$ en prueba,

$$\text{Accuracy}_{\text{prueba}} = \frac{1\,213}{1\,249} \times 100\,\% = 97{,}12\,\%.$$

Cuadro III
RESULTADOS EN ENTRENAMIENTO Y PRUEBA, RED 2–6–4

| **Métrica** | **Entrenamiento** | **Prueba** |
|---|---|---|
| Patrones | 4 997 | 1 249 |
| Correctos | 4 873 | 1 213 |
| Incorrectos | 124 | 36 |
| Exactitud global | 97,52 % | 97,12 % |
| Acierto $C_1$ Bajo peso | 0,00 % | 0,00 % |
| Acierto $C_2$ Peso normal | 98,64 % | 98,43 % |
| Acierto $C_3$ Sobrepeso | 98,96 % | 97,36 % |
| Acierto $C_4$ Obesidad | 98,98 % | 99,05 % |

La matriz de confusión del conjunto de prueba se presenta en el Cuadro IV y en la Fig. 6. Todos los errores se producen entre clases adyacentes, es decir, la red nunca confunde categorías no contiguas, como peso normal con obesidad.

Cuadro IV
MATRIZ DE CONFUSIÓN $4 \times 4$ EN EL CONJUNTO DE PRUEBA

| | $\hat{C}_1$ | $\hat{C}_2$ | $\hat{C}_3$ | $\hat{C}_4$ | **Acierto** |
|---|---|---|---|---|---|
| $C_1$ | 0 | 15 | 0 | 0 | 0,00 % |
| $C_2$ | 0 | 251 | 4 | 0 | 98,43 % |
| $C_3$ | 0 | 4 | 442 | 8 | 97,36 % |
| $C_4$ | 0 | 0 | 5 | 520 | 99,05 % |

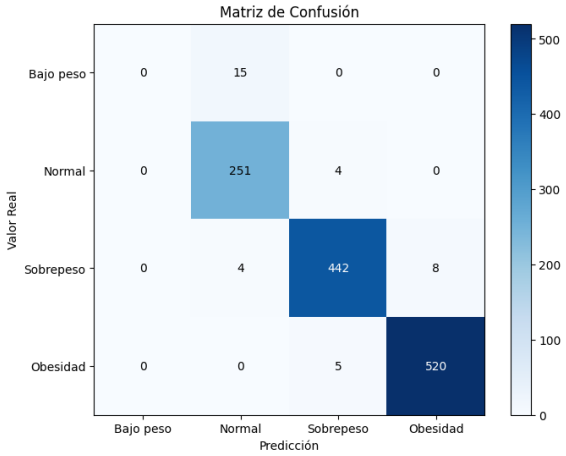



Figura 6. Matriz de confusión de la red 2–6–4 en el conjunto de prueba.

### *III-D. Análisis de errores*

Para cada patrón de prueba mal clasificado se calculó su distancia al umbral de IMC más cercano. El Cuadro V muestra que los errores se concentran fuertemente alrededor de las fronteras: 25 de los 36 errores ocurren a menos de 0,5 unidades de IMC de algún umbral, a pesar de que esa banda contiene solo 177 de los 1 249 patrones.

Cuadro V
ERRORES DE PRUEBA SEGÚN SU DISTANCIA AL UMBRAL DE IMC MÁS CERCANO

| **Banda** | **Patrones** | **Errores** | **% de errores** |
|---|---|---|---|
| $< 0{,}5$ | 177 | 25 | 69,4 % |
| $< 1$ | 339 | 31 | 86,1 % |
| $< 2$ | 703 | 35 | 97,2 % |

El Cuadro VI presenta ejemplos representativos. Los errores entre $C_2$, $C_3$ y $C_4$ corresponden a patrones prácticamente situados sobre la frontera, con IMC de 25,009 o 29,995, para los cuales una diferencia de pocos gramos determina la categoría. Por el contrario, los 15 patrones de $C_1$ fueron asignados a $C_2$ independientemente de su distancia al umbral, incluso con IMC de 16,08. El único error alejado de las fronteras corresponde a un registro de 2,222 m y 118,45 kg, valor de estatura que coincide con el código de no respuesta 222,2 cm que el filtro de rango no eliminó.

Cuadro VI
EJEMPLOS DE PATRONES DE PRUEBA MAL CLASIFICADOS

| $h$ [m] | $m$ [kg] | **IMC** | **Real** | **Predicha** |
|---|---|---|---|---|
| 1,615 | 48,25 | 18,499 | $C_1$ | $C_2$ |
| 1,412 | 32,05 | 16,075 | $C_1$ | $C_2$ |
| 1,556 | 60,55 | 25,009 | $C_3$ | $C_2$ |
| 1,721 | 73,95 | 24,968 | $C_2$ | $C_3$ |
| 1,463 | 64,20 | 29,995 | $C_3$ | $C_4$ |
| 1,530 | 70,25 | 30,010 | $C_4$ | $C_3$ |
| 2,222 | 118,45 | 23,991 | $C_2$ | $C_3$ |

## IV. DISCUSIÓN

**Limitación de una neurona lineal.** Una sola neurona lineal divide el plano altura–peso mediante una recta, mientras que las cuatro categorías están delimitadas por tres parábolas (1). Además, una neurona produce una única salida y, por tanto, solo puede separar dos regiones, de modo que resulta insuficiente tanto por la forma de las fronteras como por el número de clases.

**Papel de la activación no lineal.** Cada neurona oculta define una transición sigmoidal suave a lo largo de una dirección del plano. La capa de salida combina estas transiciones, lo que permite construir fronteras curvas por superposición. Si la activación oculta fuera lineal, la composición de ambas capas seguiría siendo una transformación afín y la red equivaldría a un clasificador lineal.

**Interpretación de los gradientes locales.** El término $\delta_j^{(2)}(k)$ mide la sensibilidad del error con respecto al potencial de la neurona de salida $j$: combina cuánto se equivocó la neurona, a través de $e_j(k)$, con cuánto puede modificarse su salida, a través de $\varphi'$. El término $\delta_j^{(1)}(k)$ representa la responsabilidad de la neurona oculta $j$ en el error total; se obtiene sumando los errores de salida ponderados por los pesos $w_{rj}^{(2)}$, ya que una neurona oculta solo afecta al error a través de las conexiones que la unen con la capa siguiente. Por ello, si dichos pesos son pequeños, el error retropropagado hacia esa neurona también lo es.

**Entrenamiento frente a prueba.** La diferencia entre la exactitud de entrenamiento, 97,52 %, y la de prueba, 97,12 %, es de apenas 0,40 puntos porcentuales, y los aciertos por clase son muy similares en ambos conjuntos. Dado que los patrones de prueba no intervinieron en el ajuste de los pesos ni en el cálculo del escalamiento, esta diferencia constituye una estimación válida de la capacidad de generalización e indica ausencia de sobreajuste, lo cual es esperable con 46 parámetros y casi 5 000 patrones.

**Ubicación de los errores.** Los errores se concentran sobre las fronteras de IMC, como confirma el Cuadro V. Esto demuestra que la red reprodujo adecuadamente las fronteras $m = 25h^2$ y $m = 30h^2$, y que sus errores residuales se deben a la incertidumbre propia de patrones casi equidistantes de dos clases. La excepción es la frontera $m = 18{,}5h^2$, que la red no aprendió.

**Efecto del desbalance de clases.** La clase $C_1$ cuenta con solo 70 patrones de entrenamiento, el 1,4 % del total. Como el entrenamiento minimiza el error cuadrático promedio, la contribución de $C_1$ a $E_{\text{av}}$ es marginal: asignar todos sus patrones a $C_2$ incrementa poco el error global, mientras que crear una región específica para ellos requeriría desplazar fronteras que afectan a miles de patrones de las otras clases. En consecuencia, la exactitud global del 97,12 % oculta una sensibilidad nula para $C_1$, lo que subraya la necesidad de reportar el acierto por clase. Este comportamiento constituye un subajuste de la clase minoritaria y podría mitigarse ponderando

el error de cada clase de forma inversamente proporcional a su frecuencia, sobremuestreando $C_1$ o utilizando una salida *softmax* con entropía cruzada.

**Efecto de la razón de aprendizaje.** Con $\eta$ demasiado pequeña la red requiere muchas épocas para alcanzar la meseta del error y puede quedar atrapada en zonas de saturación de la sigmoide, donde $\varphi' \approx 0$. Con $\eta$ demasiado grande las actualizaciones estocásticas producen oscilaciones o incluso divergencia. El valor $\eta = 0{,}01$ produjo una curva monótona y estable.

**Parámetros de normalización.** Los parámetros $\mu_j$ y $\sigma_j$ forman parte del modelo y deben estimarse únicamente con los datos de entrenamiento. Si se calculan con toda la base, la información del conjunto de prueba se filtra al modelo y la evaluación deja de representar el desempeño sobre datos verdaderamente nuevos.

**Comparación con ADALINE.** En el modelo se pasó de una neurona lineal con una salida a una red con una capa oculta no lineal y cuatro salidas sigmoidales. En el algoritmo de aprendizaje, la regla delta de ADALINE se generalizó: la actualización conserva la forma $\Delta w = \eta\, \delta\, y$, pero el término $\delta$ incorpora la derivada de la activación y, en la capa oculta, se obtiene propagando hacia atrás los gradientes locales de la salida. ADALINE alcanzó $88{,}39\,\%$ en un problema de dos clases, mientras que la red multicapa logró $97{,}12\,\%$ en un problema de cuatro clases.

**Limitaciones.**

- El parámetro de mezcla de patrones se definió en la clase, pero no se aplicó, por lo que los patrones se presentaron en el mismo orden en todas las épocas.
- No se implementó un criterio de paro basado en el error; el entrenamiento se detuvo al completar $200$ épocas.
- La salida sigmoide con error cuadrático trata cada neurona de salida de forma independiente; una salida *softmax*, cuya función se programó pero no se utilizó, produciría probabilidades normalizadas entre las cuatro clases.
- Persisten registros con los códigos de no respuesta $222{,}22$ kg y $222{,}2$ cm, que actúan como valores atípicos.

## V. Conclusiones

Se implementó desde cero un perceptrón multicapa 2–6–4 entrenado con retropropagación en modalidad estocástica, que alcanzó una exactitud de $97{,}12\,\%$ al clasificar en cuatro categorías el estado nutricional de adultos de la ENSANUT 2022 utilizando únicamente altura y peso. La curva de aprendizaje fue monótona y estable, y la similitud entre los resultados de entrenamiento y prueba indica una buena generalización.

La capa oculta permitió resolver lo que ADALINE no podía representar: la red construyó varias fronteras de decisión independientes que separan con claridad las clases peso normal, sobrepeso y obesidad, y los errores residuales se localizan casi exclusivamente en las inmediaciones de las fronteras teóricas $m = 25h^2$ y $m = 30h^2$. La principal deficiencia del modelo es la nula detección de la clase bajo peso, consecuencia directa del desbalance de clases bajo un criterio de error cuadrático. Como trabajo futuro se propone incorporar ponderación por clase o sobremuestreo, emplear una salida *softmax* con entropía cruzada y añadir un criterio de paro basado en un conjunto de validación.

## Referencias


[1] *Algoritmo de retropropagación*, apuntes de clase del curso Sistemas Inteligentes 3 – Redes Neuronales Artificiales, CUCEI, Universidad de Guadalajara, 2026.

[2] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ, USA: Pearson/Prentice Hall, 2009.

[3] B. Mehlig, *Machine Learning with Neural Networks: An Introduction for Scientists and Engineers*. Cambridge, U.K.: Cambridge University Press, 2021.

[4] C. C. Aggarwal, *Neural Networks and Deep Learning: A Textbook*. Cham, Switzerland: Springer, 2018.

[5] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[6] Instituto Nacional de Salud Pública, "Encuesta Nacional de Salud y Nutrición Continua 2022 (ENSANUT 2022): base de datos de antropometría," Cuernavaca, México: INSP, 2023. [En línea]. Disponible: https://ensanut.insp.mx